

RSNA térd-MRI

Két út a működő versenymegoldásig

- 1. Leletcímkék + több sorozatos 2.5D CNN + MIL
- 2. Leletcímkék + több sorozatos 3D CNN

Részletes fejlesztési terv a Kaggle RSNA Knee Abnormality Detection versenyhez. A kiindulópont a korábbi javaslatunk: először stabil 2.5D beadás, utána ugyanazon adatokon és validációval 3D összehasonlítás. JEPA nem része ennek a tervnek.

Javasolt döntés

A meglévő CNN- és MRI-tapasztalatodra építve a 2.5D modell adja a legjobb első fejlesztési célt. A 3D modell akkor érdemel további erőforrást, ha mérhető előnyt vagy hasznos, eltérő hibamintázatot mutat.

Szempont	2.5D megoldás	3D megoldás
Mit lát közvetlenül?	Három szomszédos szelet; utána sorozat- és vizsgálatszintű összegzés.	A sorozat térfogatát; a térbeli szűrők szeletek között is tanulnak.
Első modell	EfficientNet-B0, mean + max pooling, 12 kimenet.	Kompakt 3D ResNet-18, térbeli pooling, 12 kimenet.
Fő kockázat	Ritka, apró eltérés kimarad a mintavett szeletekből.	A felbontáscsökkentés eltünteti a kis struktúrákat; memóriaigény.
Közös sikertényező	Jó címkék, geometriai ellenőrzés, szivárgásmentes mérés.	Ugyanaz a címkeverzió és ugyanaz a betegszintű felosztás.

Olvasási útvonal

2-6. oldal: feltételek, adatok, címkézés, validáció.

7-9. oldal: a 2.5D megoldás részletes terve.

10-13. oldal: a 3D megoldás és az opcionális anatómiai ág.

14-16. oldal: beadás, ütemezés, források és fogalmak.

A dokumentum tervezési javaslat. Nem történt adatkészlet-letöltés, modelltréning vagy futásidőmérés; minden hiperparaméter kísérleti kezdőérték.

KÖZÖS ALAP / VERSENYFELTÉTELEK

Mit tudunk, mit kell rögzíteni?

Az RSNA hivatalos ismertetője több mint 5000 térd-MRI-vizsgálatot, 16 adatgyűjtő helyet és 12 nyelvű leletanyagot említ. Az értékelőadatokat szakértő radiológusok annotálták. A meghirdetett zárónap 2026. október 22. [1]

Tétel és bizonyosság	A terv következménye
Ellenőrzött: képek és többnyelvű leletek a tanítóanyagban. [1]	A leletfeldolgozás külön, verziózott tanítási előkészítés.
Hivatalos keresőkivonat: GPU notebook legfeljebb 9 óra, internet kikapcsolva. [2]	Minden modell és függőség előre csatolva; a teljes képbeolvasási időt is mérni kell.
Hivatalos keresőkivonat: szabadon és nyilvánosan elérhető külső adat és előtanított modell használható. [2]	A konkrét súlyok és adatok licence, hozzáférése, szabályokkal való egyezése külön ellenőrzendő.
Előzményből átvett munkafeltétel: 12 célcímke, osztályonkénti ROC-AUC átlaga.	12 sigmoid kimenettel tervezünk. Az Evaluation lap és a mintabeadás alapján kell véglegesíteni.
Most nem ellenőrzött: teljes Rules, pontos címkedefiníciók és beadási séma. [2-4]	A labels.yaml és a beadási adapter csak a hivatalos fájlok alapján rögzíthető.

A fejlesztés első ellenőrzőpontja

Mentsd el a verseny aktuális Data, Evaluation, Code Requirements és Rules leírását. Rögzítsd a jelentkezési és csapategyesítési határidőt, a zárás időzónáját, a napi és végső beadási limitet, a GPU-/RAM-/lemezkeretet, valamint azt, hogy fájllos vagy API-alapú a beadás. Ezeket a most elérhető forrásokból nem lehetett teljesen igazolni.

A kategórianeveket nem találhatjuk

A további oldalakon a „12 címke” a korábbi beszélgetés szerinti cél. A belső c01...c12 azonosítók helyére a hivatalos nevek, pontos sorrend és definíciók kerüljenek. A leletek 12 nyelve és a modell 12 kimenete két külön állítás.

A tervezett inferencia csak képeket és engedélyezett metaadatokat használ. Ne építs arra, hogy tesztidőben lelet is rendelkezésre áll; ezt a tényleges tesztbemenetből kell ellenőrizni.

KÖZÖS ALAP / ELŐFELDOLGOZÁS

Adatleltár és megbízható képút

1. Hozz létre vizsgálat- és sorozatszintű leltárt

Vizsgálatonként egy stabil `study_id`; sorozatonként `series_id`, betegazonosító, ha van, fájlvonal, oldaliság, szeletszám, képméret, orientáció, pixelméret, szeletköz és szekvencialeírás. A hiányokat és dekódolási hibákat külön mező jelezze. A betegazonosító csoportosításra szolgál, nem modellbemenet.

2. A geometria döntse el a szeletek sorrendjét

Az `ImageOrientationPatient` két irányvektorának keresztszorzata adja a szeletsík normálisát. Az `ImagePositionPatient` normálisra vetített értéke alapján rendezd a szeleteket. Az `InstanceNumber` és a fájlnev legfeljebb ellenőrzött tartalékmegoldás. A pixelméret és a térbeli pozíció jelentését a DICOM szabvány definiálja. [7]

Szűrd a duplikált szeleteket, a kevert geometriát, az eltérő echókat és a nem egyenletes szeletközt. A szeletvastagság nem feltétlenül azonos a szeletek középpontja közötti távolsággal.

Enhanced/multiframe DICOM esetén képkockaként is olvasd a geometriát; ne kezeld a teljes fájlt egyetlen szeletként.

3. Determinisztikus sorozatkiválasztás

Lépés	Kezdő szabály
Síkonkénti csoportosítás	Orientációból sagittalis/coronalis/axialis jelölt; ferde sorozatoknál szögtűrés és naplózás.
Szekvencia szerinti rangsor	Kezdetben PD/T2 jellegű, folyadékérzékeny sorozat előnyben; zsírelnyomás és fedettség ellenőrzése. Ez hipotézis, nem minden címkére optimális.
Minőség és lefedettség	Localizer és hibás sorozat kizárása; megfelelő térfedettség, szeletszám és felbontás.
Választás és hiány	Síkonként egy sorozat, előre rögzített holtverseny-szabály. Hiányzó sík: kitöltés és jelenléti maszk.


4. Intenzitás és gyorsítótár

Alkalmazd az adott objektumra releváns intenzitástranszformációt; ellenőrizd a MONOCHROME1 eseteket. Sorozatonként robusztus percentilis-vágás és normalizálás, a háttér kizárásával. Például p1-p99 vágás után [0,1] skála. Tárold a feldolgozott tömböt az eredeti geometriával, verzióval és forráshash-sel; a képi gyorsítótár ne tartalmazzon leletszöveget.

KÖZÖS ALAP / CÍMKE-ELŐÁLLÍTÁS

Leletből ellenőrizhető tanítócímke

A nyelvi modell feladata egy rögzített kategóriarendszer szerinti információkinyerés. Nem kaphat képi validációs diagnózist a címkézés hangolásához. A kimenet minden döntését eredeti nyelvű szövegrészlet támassza alá.



1. ábra. Címkekinyerés a tanítóoldalon. Az ellenőrzés után ugyanaz a címkeverzió táplálja mindkét képi modellt.

Javasolt eljárás

- **Definíciós szótár:** hivatalos célcímke, anatómiai hely, elfogadott állapotok, kizárások; külön szabály a műtét utáni állapotra, korábbi sérülésre és részleges eltérésre.
- **Egyszerű kontroll:** többnyelvű kifejezés- és tagadásszótár. Ezzel összevethető, hogy a nyelvi modell valóban többet ad-e, és könnyebben észrevehető a rendszerszintű tévedés.
- **Helyi modell:** többnyelvű utasításkövető modell strukturált JSON-kimenettel, rögzített prompttal és determinisztikus dekódolással. A modellméretet 30-50 leletes próbán, a rendelkezésre álló GPU szerint válaszd meg; nagyobb modell nem automatikusan jobb.
- **Automatikus ellenőrzés:** helyes JSON-séma, minden kategória jelen van, idézet megtalálható a leletben, nincs ellentmondó oldaliság vagy téves időbeliség. Hibánál egy javító kör, utána kézi sor vagy unknown.

Auditminta és verziózás

Indulásként 150-250, nyelv és ritka pozitív címke szerint rétegzett leletet ellenőriznék. Ez munkakeret, nem statisztikai garancia. Mérd kategóriánként a pozitív állítások precision/recall értékét, a tagadási hibákat és az unknown arányát. Promptmódosítás után új, korábban nem látott leletmintával is ellenőriz. Mentsd a modell-, prompt-, szótár- és címkeverziót.

KÖZÖS ALAP / ZAJOS FELÜGYELET

Címkeállapotok és tanítási veszteség

Leletállapot	y cél	w súly az alapváltozatban	Értelmezés
Jelen van	1	1,0	A cél meghatározása szerinti pozitív állítás.
Kifejezetten kizárt	0	1,0	Megbízhatóbb negatív felügyelet.
Bizonytalan / ellentmondó	0*	0	Az adott címke lossából kimarad.
Nincs említve	0	0,2	Kezdő hipotézis: gyenge negatív; külön összevetendő w=0 és w=1 beállítással.

* A 0 itt technikai helykitöltő. A nulla súly miatt nem tanít negatívként. NaN helyett véges helykitöltőt használj, mert a NaN $\times$ 0 is NaN maradhat.

Maszkolt BCE, osztályonként normalizálva

Veszteségfüggvény

Egy c címkére: $L_c = \sum_i (w_{ic} \times BCEWithLogits(z_{ic}, y_{ic})) / \max(\sum_i (w_{ic}), \epsilon)$.

L = az adott batchben nem nulla összsúlyú L_c értékek átlaga.

A z a nyers logit; a sigmoidot nem kell külön alkalmazni a BCEWithLogits előtt. A 12 kimenet egymástól független bináris feladat, ezért nem softmaxot használunk. A maszk címkéként értendő: egy vizsgálat néhány ismert címkéje akkor is taníthat, ha a többi ismeretlen. [9]

Mit jelent a megbízhatósági súly?

A 0,2 súly saját kísérleti választás, nem a leletből becsült 20%-os valószínűség. A nyelvi modell saját „confidence” értéke sem kalibrált mérőszám. Az állapothoz rendelt súlyokat az audit és a fejlesztési validáció alapján módosítsd; ugyanazt a szabályt használd a 2.5D és 3D összevetésben.


Ritka címkék

Kezdetben ne kombinálj erős oversamplinget és nagy pos_weight értéket. Először súlyozatlan, maszkolt BCE legyen a referencia. Ha egy ritka osztály nem tanul, próbálj mérsékelt, korlátozott pozitív súlyt vagy betegszintű mintavételt, egyszerre csak az egyiket. A pos_weight kizárólag a tanító foldból származzon.

Mentendő minimális címkeséma

study_id, target_name, state, y, weight, evidence, language, label_version, audit_flag. A leletaudit annak helyességét ellenőrzi, hogy mit mond a szöveg. A képi audit azt, hogy mi látszik az MRI-n; a kettő eltérhet, ezért külön referenciaként kezeld őket.

Validáció, amelyből dönteni lehet



2. ábra. Példafelosztás. A pontos arányt a ritka címkék és a betegazonosítók elérhetősége alapján kell megválasztani.

Betegcsoportosítás: ugyanazon beteg minden vizsgálata, mindkét térde és minden sorozata egy részbe kerüljön. Ha nincs megbízható betegazonosító, vizsgálatszintű felosztás és duplikátumkeresés szükséges; a betegszintű függetlenséget ekkor nem lehet garantálni.

Fejlesztési elrendezés: például 20% zárt ellenőrző rész, a maradékon 3 csoportosított fold. Többcímkés rétegzés segíthet, de minden foldban külön ellenőrizd a pozitív és negatív esetszámot. Intézményi holdoutot csak valódi helyazonosító és elég adat esetén adj hozzá; a leletnyelv nem biztos intézményazonosító.

Kétféle referencia: gyenge, leletből képzett címkéken széles körű mérés; ha engedélyezetten elérhető, külön képi szakértői referencia. Utóbbi hiányában mondd ki, hogy csak leletcímkéhez viszonyított teljesítményt mérsz. Kézi képi auditot megfelelő radiológiai közreműködéssel tervezd.

Mit tartalmazzon minden mérési eredmény?

Makro ROC-AUC; a 12 osztály AUC-ja és pozitív/negatív esetszáma; tanítási címkeverzió; fold és seed; GPU-csúcsmemória; teljes inferenciaidő. Egyosztályos alcsoport AUC-ja nem definiált: ne helyettesítsd önkényesen 0,5-tel. A modelleket párosított, betegszintű bootstrap bizonytalansággal is hasonlítsd össze, például 1000 újramintázással.


A zárt rész szerepe

Az architektúra, címkesúly és ensemble-súly kiválasztása a fejlesztési foldokon történjen. A zárt rész a befagyasztott recept egyszeri ellenőrzése. Ha az eredménye alapján tovább hangolsz, többé nem tekinthető független ellenőrzésnek.

ARCHITEKTÚRA / ELSŐKÉNT EZT ÉPÍTENÉM

1. megoldás: 2.5D CNN és MIL

Egy vizsgálatot szeletcsomagok halmazaként dolgozunk fel. Minden csomag három, eredetileg is szomszédos szeletből áll. A 2D CNN helyi térbeli kontextust lát; a teljes vizsgálat címkéjét az aggregálás után tanítjuk. Ez a multiple-instance learning, röviden MIL logikája. [5]



3. ábra. Alapváltozat három sorozattal. S a központi szeletek száma. A példában EfficientNet-B0 globálisan poolozott jellemzőmérete 1280. [6]

A tenzorok útja

Bemenet: $[B, 3, S, 3, 256, 256]$, ahol B a vizsgálatok száma, az első 3 a sorozathelyek száma, a második 3 a szomszédos szeleteké. A CNN számára az érvényes csomagokat $[N, 3, 256, 256]$ alakban egyesítjük. Az egyes csomagokból 1280 elemű jellemzővektor lesz.

Alap pooling: sorozatonként a szeletjellemzők átlagát és dimenzióként maximumát összefűzzük: 2560 elem/sorozat. Három sorozat és 3 jelenléti jelző összesen 7683 elem. Fej: Linear(7683, 256), ReLU, Dropout(0,2), Linear(256, 12). A hiányzó sorozatvektor nulla, a maszk jelzi a hiányát.

Második változat: attention pooling

Az átlag/max helyett a modell tanulhat szeletsúlyokat: $a_s = \text{softmax}(g(h_s))$, majd $z = \sum_s (a_s \times h_s)$. Csak az érvényes szeletek vehetnek részt a softmaxban. Ez változtatja a fej bemeneti méretét is. Az attention hasznos hibakeresési jelzés, de nem tekintendő igazolt léziólokalizációnak. [5]

MEGVALÓSÍTÁS / KEZDŐ KONFIGURÁCIÓ

2.5D: mintavétel és tanítás

A három szelet helyes összeállítása

Először válaszd ki az eredeti rendezett sorozatban a központi indexeket. Az i középpont bemenete $[i-1, i, i+1]$, nem a ritkított lista három egymás utáni eleme. A széleken ismételd a szélső szeletet. Rövid sorozatnál a kitöltött központokat maszkolni kell, hogy ismétlődésük ne kapjon nagyobb pooling-súlyt.

Kezdetben $S=24$ központ/sorozat. Tanításkor egyenletes szakaszokból kis véletlen eltolással mintavételezz; validációkor rögzített központokat használj. $S=32$, majd szükség esetén 48 összevetésével mérd az apró eltérések kimaradásának hatását. A képen belüli crop őrizze meg a térd teljes releváns területét.

Paraméter	Induló érték / eljárás
Encoder és inicializálás	EfficientNet-B0, ellenőrzött és előre letöltött ImageNet-súlyok. A három csatorna MRI-szelet, ezért az előtanítás hasznát mérni kell.
Képméret és batch	256×256 ; kezdetben 1-2 vizsgálat/batch. Gradiensakkumulációval 8-16 effektív vizsgálat, ha stabil.
Optimalizálás	AdamW; encoder LR $1e-4$, fej LR $3e-4$, weight decay $1e-4$. 1-2 epoch bemelegítés, majd cosine csökkentés.
Tanítási hossz	Legfeljebb 20-30 epoch, 5 epoch türelem a fejlesztési makro-AUC alapján; foldonként legjobb checkpoint.
Numerika és normalizálás	Vegyes pontosság, támogatástól függően bf16/fp16. Kis vizsgálati batch esetén BatchNorm-statisztika befagyasztásának összevetése.
Augmentáció	Enyhe síkbeli forgatás, eltolás és skálázás, intenzitáseltolás és zaj. Egy sorozat összes szeletén azonos geometriai transzformáció.

Memória és hibakeresés

A példában $B=2$, 3 sorozat és 24 központ már 144 CNN-képet jelent lépésenként. A nyers bemenet fp16-ban körülbelül 54 MiB, de a tanítási aktivációk ennek sokszorosát igényelhetik. A képenkénti feldarabolás inferencián segít; tanításkor a teljes gradiensgráf tárolása miatt önmagában nem biztosít nagy megtakarítást. Csökkents B -t, vagy használj ellenőrzött activation checkpointingot.

Először 8-16 vizsgálatot próbálj túlilleszteni augmentáció nélkül. Ha a loss nem csökken jelentősen, vizsgáld a címke-illesztést, maszkot, gradiensútvonalat és szeletrendet, mielőtt nagy tréninget indítasz.

MEGVALÓSÍTÁS / DÖNTÉSI PONTOK

2.5D: kísérleti sorrend és kész eredmény

Lépés	Mi változik?	Mikor lépj tovább?
A0: technikai próba	8-16 vizsgálat túlillesztése, majd 50-100 vizsgálatos teljes képút.	Véges loss, mind a 12 kimenet megvan, minden vizsgálat feldolgozható vagy naplózott fallbackot kap.
A1: referencia	B0, S=24, 256 px, mean + max, közös címkeverzió.	Egy fold végigfut, checkpoint és OOF táblázat kész; működő offline beadási próba.
A2: címkekísérlet	Nem említett címke súlya: 0 / 0,2 / 1.	A különbség több osztályon és lehetőleg több foldon értelmezhető; a mintaszámokat is vizsgálad.
A3: szeletenkénti fedés	S=24 → 32; csak indokolt esetben 48.	Az AUC-javulás és a teljes futásidő együtt indokolja a nagyobb mintát.
A4: pooling	Mean + max → egyszerű attention.	Több foldon reprodukálható előny, vagy hasznos eltérő hibák.
A5: nagyobb modell	B0 → B2 vagy 256 → 320 px, külön kísérletben.	A validációs nyereség megéri a plusz számítást.

A hibaanalízis konkrét kérdései

- A pozitív esetben benne van-e a jel a kiválasztott sorozatban és a mintavett szeletekben? Ha nincs, az encoder növelése nem oldja meg a problémát.
- A lelet negatívnak kódolt állapota tényleg a célstruktúrára és a vizsgált térdre vonatkozik? Műtéti állapot vagy korábbi sérülés okozza az eltérést?
- Egy bizonyos nyelv, szkennel, hiányzó sík vagy szekvencia gyengébb? Válaszd szét a címkehibát, a képút hibáját és a modellhibát.

Az első kész megoldás legkisebb hasznos csomagja


Verziózott adatleltár és címkék; beteg/fold megfeleltetés; egy reprodukálható konfiguráció; tanítószkript; validációs predikciók és osztályonkénti AUC; egy checkpoint; offline inferencia; a hivatalos sémát követő beadás. Az attention, több foldból álló ensemble és TTA későbbi bővítés.

Mikor elég ez a megoldás?

Ha stabilan feldolgozza az adatokat, reprodukálható a fejlesztési eredmény, és marad futásidő-tartalék, már van használható beadás. A 3D modell fejlesztését ehhez a befagyasztott referenciához mérd.

2. megoldás: több sorozatos 3D CNN

Minden kiválasztott sorozat önálló térfogatként kerül egy kompakt 3D encoderbe. A modell lokális szűrői a szeletek irányában is mozognak. A különböző síkok és szekvenciák összevonása a jellemzők szintjén történik, ezért nem szükséges az összes sorozat voxelről voxelre történő regisztrációja.



4. ábra. Példa 512 elemű kimeneti jellemzőt adó 3D ResNet-18 változattal. A residual felépítés alapja [8]; a 3D és anizotrop változat itt tervezési választás.

Pontos induló struktúra

Sorozatbemenet: $[B, 1, D, H, W]$, első próba $D=48, H=W=192$. Három sorozathely esetén a teljes batch $[B, 3, 1, 48, 192, 192]$. A három ág kezdetben ugyanazokat a súlyokat használja; ez csökkenti a paraméterszámot, de nem harmadolja a számításigényt.

Encoder: négy residual szint például 64/128/256/512 csatornával, szintenként két alaplakkal. Globális térbeli átlagpooling után 512 elem/sorozat. Fúzió: $3 \times 512 + 3$ jelenléti jelző = 1539 elem, majd Linear(1539,256), ReLU, Dropout(0,2), Linear(256,12). A kimenet ismét vizsgálat szintű.

Miért ne egyetlen háromcsatornás térfogat legyen?

Az azonos tömbméret nem jelent azonos anatómiai koordinátákat. A sagittalis és coronalis sorozat egyszerű csatornaként összefűzése hibás megfeleltetést hozhat létre. A külön encoder-futtatás utáni jellemzőfúziót választanám. Külön ágparamétereket csak akkor próbálnék, ha a közös súlyok nem kezelik jól a síkok közötti eltérést.

MEGVALÓSÍTÁS / AZ INFORMÁCIÓ MEGŐRZÉSE

3D: geometria és felbontás

A fix tömbméret önmagában nem előfeldolgozási szabály

Tartsd meg a sorozat affine transzformációját és a voxelméretet. Sorozatsíkonként legyen következetes az irány és a tengelyek sorrendje. Az egyszerű transzponálás/tükrözés a tengelyek sorrendjét javítja; a ferde sík valódi újramintavételezése külön geometriai művelet.

Döntés	Induló megoldás	Mit ellenőriz?
Tengelyrend	D a sorozat normálisa, H/W a síkbeli tengelyek; a síktípushoz tartozó irányok egységesek.	Jobb/bal, elülső/hátsó és felső/alsó irányok a képen helyesek.
Voxelméret	Síkonként a tanítóadatokból választott referencia, a jellemző vastag szeletirány megtartásával.	Ne hozz létre látszólagos részletet erős izotrop felnagyítással.
Térdfedettség	Tág foreground crop, margóval; aztán fizikai méretet figyelembe vevő crop/pad.	Meniscus, szalagok és perifériás eltérések ne kerüljenek a kivágáson kívülre.
Fix bemenet	48 × 192 × 192 első méréshez. Ha nem fedi a térdet, nagyobb D/FOV vagy ablakos feldolgozás.	Ne kényszeríts minden térfogatot eltérő torzítással ugyanarra a formára.
Intenzitás	A közös képúttal azonos, sorozatonkénti robusztus skálázás.	Háttér, mozgás és zsírelnyomás különbségei.

Anizotrop konvolúció mint kezdő választás

Vastag szeleteknél az első konvolúció lehet (1,7,7), (1,2,2) stride-dal; a korai blokkokban (1,3,3) kernel, a mélyebb szinteken (3,3,3). A D tengelyt csak később csökkentsd. Ez kevésbé mossza össze korán a gyengébb felbontású irányt. A részletes stride-listát a választott implementációban külön rögzíteni kell.

Elfogadási próba

Induláskor legalább 30-50 változatos sorozatból készíts eredeti és feldolgozott középszelet-nézeteket mindhárom síkban. Ellenőrizd a szélső szeleteket és a crop határait is. Ha kisméretű jel eltűnik, először a térbeli felbontást vagy a fedést javítsd. Sem interpoláció, sem nagyobb hálózat nem állítja vissza a már elvesztett részletet.

MEGVALÓSÍTÁS / KONTROLLÁLT BŐVÍTÉS

3D: tanítás és összehasonlító kísérletek

Paraméter	Induló választás
Inicializálás	Véletlen inicializálás mint biztosan reprodukálható kontroll. 3D előtanított súly külön kísérlet, csak illeszkedő architektúrával és engedélyezett licenccel.
Batch és numerika	1-2 vizsgálat/batch, AMP, akkumulációval 8 effektív vizsgálat; GroupNorm kezdésnek kis batchhez.
Optimalizálás	AdamW, LR $3e-4$ véletlen inicializáláshoz; előtanított encoderhez inkább $3e-5$ - $1e-4$. Weight decay $1e-4$, 2 epoch warmup, cosine LR.
Tanítási keret	Legfeljebb 30-50 epoch, 7 epoch türelem; a rendelkezésre álló GPU-idő korlátozhatja. Nincs ígért tréningidő.
Augmentáció	Kis térbeli eltolás/forgatás és skálázás, enyhe intenzitás- és zajmódosítás. A térfogat szeleteit ne transzformáld egymástól függetlenül.
Loss és címkék	Pontosan ugyanaz a címkeverzió és a maszkolt BCE, mint a befagyasztott 2.5D kontrollnál.

Kísérleti sorrend

B0: egyetlen, megbízhatóan elérhető sorozattal 8-16 vizsgálat túlillesztése. **B1:** ugyanebből egy teljes fejlesztési fold, majd három sorozat és közös encoder. **B2:** $D=48 \rightarrow 64$, vagy $192 \rightarrow 224$ képméret, külön kísérletben. **B3:** illeszkedő előtanítás kipróbálása. **B4:** külön sorozatágak vagy ROI kizárólag a hibaelemzés alapján.

A $48 \times 192 \times 192$ bemenetet $64 \times 224 \times 224$ -re növelve a voxel- és hozzávetőleges aktivációmennyiség 1,81-szeres lesz, azonos hálózat mellett. Ez kapacitásbecslés, nem futásidőmérés. Az encoder sorozatonkénti futtatása és activation checkpointing csökkentheti a memóriaigényt, de időt kérhet cserébe.

Tisztességes 2.5D-3D összevetés

Azonos betegek, címkeverzió, sorozatok és értékelő kód. Két nézetet ments: azonos, előre vállalt fejlesztési számítási keret mellett elért eredmény; illetve a végső inferenciakeretbe férő legjobb konfigurációk összevetése. Egy gyengén beállított 3D első futásból ne következtess általánosan a 3D módszer értékére.


A 3D folytatásának feltétele

Folytasd, ha több foldon javít, vagy az OOF predikcióinak 2.5D-vel való keverése javulást mutat elfogadható futásidővel. Ha egyik sem teljesül, a 2.5D beadás maradjon az elsődleges eredmény.

CSAK INDOKOLT HIBAMINTÁZAT ESETÉN

Opcionális 3D bővítés: anatómiai ROI

ROI = region of interest, vagyis célzott képkivágás. Akkor érdemes bevezetni, ha a teljes térdet feldolgozó modell a felbontás miatt elveszíti egy kis struktúra jelét. A globális ág megmarad, mert egy szűk kivágásból kimaradhatnak más célkategóriák.



5. ábra. Globális és célzott ág. A lokalizáló önállóan megoldandó feladat; a kivágás nem igényelhet kézi beavatkozást a tesztadatokon.

A lokalizálás megvalósítható terve

Válassz a hibaanalízisből egy konkrét célt, például a meniscusok régióját. Ha rendelkezésre áll jogszerűen használható annotáció, taníts egyszerű 3D középpont-regresszort vagy hőtérképes lokalizátort. Egyébként tervezd külön, szakértő által ellenőrzött tanítóoldali ROI-annotálást; ennek költsége és ideje a bővítés része.


A lokalizátort kizárólag az adott fold tanítórészén tanítsd. A crop középpontját fizikai koordinátára alakítsd, majd az adott sorozat affine inverzével keresd vissza a voxelt. Másik síkba átvitt ROI-nál az azonos betegkoordináta sem garantál mozgásmentes sorozatok közötti megfelelést; ellenőrzés és margó kell.

Próba, összevetés és visszaesési út

A crop fizikai méretét az anatómiai fedésből válaszd, ne egyetlen példaképből. Mérd a régió lefedettségét és a kivágási hibák arányát is. Hasonlítsd össze a globális modellt a globális + ROI modellel azonos foldokon; mérd a plusz dekódolási, lokalizálási és encoderidőt.

Hibás vagy alacsony megbízhatóságú lokalizálásnál a globális ágnak önmagában is működnie kell. A tanításban időnként hagyd el a ROI-t. A figyelmi súly vagy Grad-CAM csúcsa önmagában nem elég megbízható anatómiai crop-meghatározás.

Offline inferencia és beadás



6. ábra. Beadási adatút. A leletkinyerő nyelvi modell nem része az itt tervezett tesztinferencia-csomagnak.

A teljes időt mérd

T_{teljes} = környezetindítás + modellbetöltés + DICOM-dekódolás + előfeldolgozás + modellfuttatás + kimenet. A 9 órás GPU-korláthoz belső célként legfeljebb 6,5-7 órát vállalnék, hogy maradjon tartalék az eltérő tesztméretekre és lassú vizsgálatokra. Ez saját tervezési tartalék. [2]

Mérv reprezentatív, például 100-200 vizsgálatos csomagot hideg gyorsítótárral; ments medián és p95 időt, szeletszámot, hibaarányt. A teljes időt a teszt várható méretével skálázd, majd ellenőrizd a hivatalos futtatóban. A TTA és minden további modell csak mért időelőny/eredmény arány alapján kerüljön be.

Ha mindkét modell hasznos

Kezdj az egyszerű $p = 0,5 \times p_{2.5D} + 0,5 \times p_{3D}$ átlaggal. A fejlesztési OOF adatokon legfeljebb néhány előre rögzített globális súlyt próbálj, például 0,25 / 0,5 / 0,75. Az osztályonkénti sok szabad súly könnyen túlilleszkedik. A kiválasztott súly rögzített legyen a zárolt mérés előtt.

A beadás elfogadási listája

Minden szükséges súly és függőség helyben elérhető; a decoder a tényleges tömörítéseket kezeli; minden előírt azonosító pontosan egyszer szerepel; a 12 oszlop neve és sorrendje a hivatalos séma szerinti; az értékek végesek és [0,1] közöttiek. A valós beadási API vagy fájlséma vezérelje az adaptert, ne egy kitalált submission.csv formátum.

Hiányzó síkot a tanított maszk kezeljen. Teljesen olvashatatlan vizsgálatra előre rögzített, tanítóoldali osztályprior adhat technikai fallbackot, ha a szabályok engedik; ezt a validációban is szimuláld, és naplózd. A fallback csak a kimenet teljességét biztosítja, nem tekinthető sikeres képi felismerésnek.

MEGVALÓSÍTÁS / ÁTADHATÓ EREDMÉNYEK

Fejlesztési sorrend és munkacsomagok

A szeptember 9-i kiindulástól az RSNA által megadott október 22-i zárásig körülbelül hat hét van. Az alábbi beosztás prioritási terv, nem személyes időkerettedre vagy ismert GPU-ra készített órabeclés. A pontos Kaggle-határidőket az első szakaszban kell rögzíteni. [1]

Időablak	Feladat	Kész eredmény
Szept. 9-15.	Feltételek és adatséma; leltár, geometria, label-audit, betegfelosztás.	Verziózott manifest, labels, splits; szemrevételezett képút.
Szept. 16-22.	2.5D referencia és első offline próba.	Egy fold eredménye; checkpoint; működő beadási adapter.
Szept. 23-29.	Címkesúly és szeletfedés; 2.5D recept rögzítése.	Összehasonlítható OOF predikciók, rövid hibajegyzék.
Szept. 30. - okt. 6.	3D kontroll és háromsorozatos modell.	Azonos adatokon AUC-, memória- és időösszevetés.
Okt. 7-13.	Legfeljebb 1-2 indokolt bővítés; ensemble döntés.	Befagyasztott recept és globális keverési súly.
Okt. 14-20.	Zárolt ellenőrzés, végső újratanítás és offline főpróba.	Végső súlyok, verziózott inferenciacsomag, tartalék beadás.
Okt. 21-22.	Beadási tartalék; új architektúra már ne kerüljön be.	Ellenőrzött beadási státusz és archivált konfiguráció.

Közös programmodulok és szerződések

build_manifest: DICOM → sorozatleltár és geometriai hibajegyzék.
extract_labels: lelet + kategóriaszótár → állapot, y, w, evidence.
make_splits: vizsgálatok + betegcsoportok → változatlan foldtábla.
dataset_25d / dataset_3d: manifest + config → kép, sorozatmaszk, y, w.
train / evaluate: checkpoint és konfiguráció → vizsgálatonkénti OOF.
predict / submit_adapter: tesztképek → hivatalos beadási formátum.

Mi maradjon ki, ha szűk az idő?

Először ROI, nagy modellkeresés, sok TTA és osztályonként hangolt ensemble maradjon el. A teljes 3D irány is elhagyható, ha veszélyezteti a működő beadást. A címkeaudit, a betegcsoportok ellenőrzése, a reprodukálható 2.5D kontroll és az offline főpróba kapjon elsőbbséget.

HIVATKOZÁSOK / ELLENŐRIZVE: 2026. SZEPTEMBER 9.

Források és rövid fogalomtár

[1] RSNA: AI Challenge Knee MRI (2026. augusztus 5.)

Hivatalos adateleírás, szakértői értékelőcímkék, meghirdetett zárónap.

[2] Kaggle: RSNA Knee Abnormality Detection

A hivatalos keresőkivonatból ellenőrzött kódkeret és külsőadat-elv; a teljes oldal nem volt kiolvasható.

[3] Kaggle: Evaluation

Elsődleges ellenőrzési pont; tartalma most nem volt kiolvasható. A 12 címke/makro-AUC az előzményből átvett munkafeltétel.

[4] Kaggle: Rules

A részletes szabályok ellenőrzési helye; teljes tartalma most nem volt kiolvasható.

[5] Ilse, Tomczak, Welling: Attention-based Deep Multiple Instance Learning

MIL és tanulható attention aggregálás; módszertani alap, nem erre a versenyre mért eredmény.

[6] Tan, Le: EfficientNet: Rethinking Model Scaling for CNNs

A 2D encoder család módszertani forrása.

[7] DICOM Standard: Image Plane Module, C.7.6.2

Orientáció, képpozíció és pixelméret definíciói.

[8] He és mtsai.: Deep Residual Learning for Image Recognition

A residual architektúra alapja; nem a javasolt konkrét 3D változat validációja.

[9] PyTorch: BCEWithLogitsLoss

Implementációs referencia a numerikusan stabil BCE-hez.

[10] Stanford: MRNet dataset és verseny

Térd-MRI előzmény és betegsúlyú felosztási példa. Az adathasználat külön feltétel-ellenőrzést igényel.

Fogalomtár

2.5D: néhány szomszédos szelet 2D modell bemeneti csatornáiként. **3D CNN:** térfogaton mozgó konvolúciós szűrők. **MIL:** csoportosított címkéből tanulás, például vizsgálatcímke szeletcímke nélkül. **OOF:** az adott modellt tanító foldon kívüli adatokra készített predikció. **Makro-AUC:** osztályonkénti AUC-k azonos súlyú átlaga. **ROI:** célzott térbeli kivágás. **TTA:** több transzformált tesztbemenet predikcióinak összegzése. **AMP:** vegyes pontosságú számítás.

A hálózati méretek, kezdő hiperparaméterek, címkesúlyok, auditminták, munkasorrend és döntési feltételek saját tervezési javaslatok. A források a módszertani hátteret és a külön megjelölt versenyadatokat támasztják alá; nem igazolnak előre várható versenypontszámot.